

STT1000 - Exercices # 2

Automne 2021

Tout comme en cours, on utilise les conventions : Y_1, \dots, Y_n sont des variables aléatoires, y_1, \dots, y_n sont les observations (données). Les échantillons aléatoire et observé associés seront notés $\mathbf{Y} = (Y_1, \dots, Y_n)$ et $\mathbf{y} = (y_1, \dots, y_n)$. La notation Z sera (principalement) réservée pour une variable aléatoire suivant une loi normale centrée réduite, $Z \sim \mathcal{N}(0, 1)$.

Certains exercices impliquent des jeux de données parfois de grande taille. Ces jeux de données sont tous stockés au sein du chier STT1000.RData (disponible sous la plateforme moodle) qu'il convient de charger de la façon suivante :

Exercice 1 – (*Poids joueurs*)

Le tableau ci-dessus résume les poids exprimés en livres des 45 joueurs qui se sont présentés au camp d'entraînement de l'équipe de football d'une université Canadienne en juin dernier. Le jeu de données brut est stocké dans le vecteur `poids` et celui rangé en classe dans le vecteur `cut.poids`

poids	effectif
[190, 200)	15
[200, 210)	12
[210, 220)	9
[220, 235)	6
[235, 255)	3

1. Dessiner l'histogramme de ces données.
2. La variable poids semble-t-elle suivre une loi normale ?
3. Trouver une valeur approximative de la proportion des joueurs dont le poids était supérieur à 230 livres.
4. Trouver une valeur approximative de la moyenne des poids des joueurs.

Exercice 2 – (*Publicité*)

Lors d'une enquête sur la publicité télévisée on a demandé à 16 sujets d'évaluer, en minutes, le temps des coupures publicitaires pendant le lm du dimanche soir sur une chaîne. Voici les résultats (stockés dans la variable `pub` en R) :

```
[1] 28 29 30 30 31 32 32 32 33 33 33 33 34 34 35 39
```

1. Trouver la médiane, le premier quartile, et le troisième quartile de ces données.
2. Tracer le diagramme en boîte de ces données.
3. La loi normale est-elle un modèle approprié ?

Exercice 3 – (*Naissances*)

Le jeu de données "présenté en annexe (et qui fait partie du fichier STT1000.RData sous le nom `naissances`), provient d'un hôpital de Brisbane (côte est de l'Australie). Des naissances (44) ont été enregistrées sur une période de 24 heures ; pour chacune des naissances, nous observons : Heure de naissance (format hh :mm) (`[Heure]`) ; Sexe du nouveau né (`[Sexe]`) ; Poids à la naissance en grammes (`[Poids]`) ; Nombre de minutes après minuit pour chaque naissance (`[Temps]`).

1. Quels sont les types des variables `[Sexe]` et `[Poids]` ?
2. Représentez les données concernant le sexe à l'aide d'un diagramme en bâtons et d'un tableau

3. Évaluez la médiane.
4. Réalisez un histogramme de la distribution du poids ; choisissez le nombre de classes qui vous semble adéquat pour la distribution.
5. Décrivez la distribution de poids par sexe. Estimez l'étendue, l'intervalle interquartile, la médiane et la moyenne de poids par sexe.

Exercice 4 – (Naissances - suite)

Dans cette partie vous allez résoudre les questions à la main, toutefois, vous pouvez utiliser R. Pour minimiser un certain nombre de calculs, des tableaux sont fournis après chaque item. Vous pouvez vous en servir

1. Vous remarquerez que la proportion des nouveaux nés garçons est plus élevée que la proportion attendue par la loi de la génétique (la probabilité que le sexe d'un nouveau né soit un garçon ou une fille est environ de $1/2$). Est-ce que le résultat observé est si inhabituel que cela ? En répondant à cette question, calculez la probabilité d'observer au moins 26 enfants de même sexe. On suppose que la naissance d'une fille ou d'un garçon est équiprobable.
2. On peut utiliser la distribution géométrique pour modéliser le nombre de naissances jusqu'à l'obtention d'un garçon (incluant celui-ci). En ne considérant les données que jusqu'à la dernière naissance d'un garçon (donc en ne considérant que les 41 premières observations), construisez un tableau où vous compterez le nombre d'essais avant d'obtenir un garçon (le tableau en question a la même forme que le tableau de l'exemple 7 du chapitre 1 ; les lignes du tableau correspondent au nombre d'essais possibles : 1, 2, 3, 4 et 5+). Utilisez ensuite la probabilité observée que le sexe d'un nouveau né soit un garçon (sur les 41 naissances) durant cette expérience pour calculer la probabilité théorique donnée selon une loi géométrique. Comparez les probabilités empiriques et théoriques. Est-ce que la loi géométrique vous paraît un modèle adéquat ?

nb naissance jusqu'à la naissance d'un garçon	fréq.	probabilité empirique	probabilité théorique
1	18		
2	3		
3	4		
4	0		
5+	1		
total	26	100%	100%

3. La distribution de Poisson peut être utilisée pour modéliser le nombre de naissances par heures. Réalisez un tableau de façon similaire à la question précédente où chaque ligne du tableau contient ici le nombre de naissances par heure (0, 1, 2, 3, 4, 5+). Calculez à partir des données la distribution observée. Calculez ensuite le nombre de naissances moyen par heure, et calculez les probabilités théoriques selon une loi de Poisson de paramètre λ . Comparez les probabilités empiriques et théoriques. Est-ce que la loi géométrique vous paraît un modèle adéquat ?

nb naissance par heure	fréq.	probabilité empirique	probabilité théorique
0	3		
1	8		
2	6		
3	4		
4	3		
5+	0		
total	24	100%	100%

4. Après avoir ajusté la distribution de Poisson aux temps d'arrivée, il est naturel d'essayer d'ajuster la distribution exponentielle aux temps d'attente entre les arrivées. Vous allez encore construire un tableau similaire aux questions précédentes. Ici, chaque ligne du tableau correspondra à un intervalle de temps : [0, 19.5 min), [19.5, 39 min), [39.5, 58.5 min), [58.5, 78 min), 78+ min. Analysez les données pour compter les fréquences observées et déduisez-en les probabilités empiriques. Sachant que la première naissance arrive à 00h05 et la dernière à 23h55, calculez le temps moyen entre arrivées $\lambda = 1/\mu$, et utilisez cet estimate pour calculer les probabilités théoriques pour chaque classe. Comparez les probabilités empiriques et théoriques. Est-ce que la loi géométrique vous paraît un modèle adéquat ?

temps entre arrivées	fréq.	probabilité empirique	probabilité théorique
[0, 19.5)	18		
[19.5, 39)	12		
[39, 58.5)	5		
[58.5, 78)	6		
78+	2		
total	43	100%	100%
