



STT 1000 - STATISTIQUES

ARTHUR CHARPENTIER



Modèle paramétrique

Formalisation du problème : nous supposons disposer de Y_1, \dots, Y_n copies indépendantes d'une variable aléatoire Y dont la densité est paramétré par un paramètre réel ($\theta \in \Theta \subset \mathbb{R}$) ou vectoriel ($\theta \in \Theta \subset \mathbb{R}^k$).

On notera $\{Y_1, \dots, Y_n\} \stackrel{\text{i.i.d.}}{\sim} F_\theta \in \mathcal{F}$ où \mathcal{F} est la famille de lois

Exemples :

- ▶ Loi de Bernoulli $Y \sim \mathcal{B}(p)$, $\theta = p \in (0, 1)$ ou $\theta = \frac{p}{1-p} \in \mathbb{R}_+$
- ▶ Loi de Poisson $Y \sim \mathcal{P}(\lambda)$, $\theta = \lambda \in \mathbb{R}_+$, ou $\theta = \log \lambda \in \mathbb{R}$
- ▶ Loi normale $\mathcal{N}(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+$

Identifiabilité

L'application $\theta \mapsto F_\theta$ est injective,

$$\theta_1 \neq \theta_2 \implies F_{\theta_1} \neq F_{\theta_2}$$

Modèle paramétrique

Example: Le modèle Gaussien, sur \mathbb{R}

$$\mathcal{F} = \left\{ f_{\theta}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right); \theta = (\mu, \sigma^2) \right\}.$$

où $\mu \in \mathbb{R}$ et $\sigma > 0$. Alors

$$f_{\theta_1} = f_{\theta_2}$$

$$\iff \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{1}{2\sigma_1^2}(x - \mu_1)^2\right) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{1}{2\sigma_2^2}(x - \mu_2)^2\right)$$

$$\iff \frac{1}{\sigma_1^2}(x - \mu_1)^2 + \log \sigma_1 = \frac{1}{\sigma_2^2}(x - \mu_2)^2 + \log \sigma_2$$

$$\iff x^2 \left(\frac{1}{\sigma_1^2} - \frac{1}{\sigma_2^2} \right) - 2x \left(\frac{\mu_1}{\sigma_1^2} - \frac{\mu_2}{\sigma_2^2} \right) + \left(\frac{\mu_1^2}{\sigma_1^2} - \frac{\mu_2^2}{\sigma_2^2} + \log \sigma_1 - \log \sigma_2 \right) = 0$$

Modèle paramétrique

Example: Le modèle mélange d'exponentielles, sur \mathbb{R}_+

$$\mathcal{F} = \left\{ f_{\theta}(x) = \alpha\lambda_1 e^{-\lambda_1 x} + (1 - \alpha)\lambda_2 e^{-\lambda_2 x}; \theta = (\alpha, \lambda_1, \lambda_2) \right\}.$$

où $\alpha \in (0, 1)$ et $\lambda_1, \lambda_2 > 0$.

soient $\theta_1 = (\alpha, \lambda_1, \lambda_2)$ et $\theta_2 = (1 - \alpha, \lambda_2, \lambda_1)$,

$$\theta_1 \neq \theta_2 \text{ mais } f_{\theta_1} = f_{\theta_2}$$

Ce modèle n'est alors pas identifiable...

Modèle paramétrique

θ est le paramètre (en général inconnu) de la loi F_θ

Θ est l'espace des paramètres

$\mathbf{Y} = (Y_1, \dots, Y_n)$ est un échantillon aléatoire de n copies indépendantes de loi f_θ

$\mathbf{y} = (y_1, \dots, y_n)$ les valeurs observées de $\mathbf{Y} = (Y_1, \dots, Y_n)$
 n la taille de l'échantillon

Modèle paramétrique

Un estimateur d'un paramètre θ est une variable aléatoire (fonction de l'échantillon \mathbf{Y}) et est noté $\hat{\theta}(\mathbf{Y})$. La valeur estimée de $\hat{\theta}(\mathbf{Y})$ s'appelle aussi estimation et est notée $\hat{\theta}(\mathbf{y})$.

(dans de nombreux ouvrages, $\hat{\theta}$ désigne aussi bien $\hat{\theta}(\mathbf{y})$ que $\hat{\theta}(\mathbf{Y})$)
L'**estimateur** est une variable aléatoire $\hat{\theta}(\mathbf{Y})$ et l'**estimation** est une constante $\hat{\theta}(\mathbf{y})$

Exemple : observations suivant une loi $\mathcal{N}(\theta, 1)$

$$\hat{\theta}_1(\mathbf{Y}) = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \text{ et } \hat{\theta}_1(\mathbf{y}) = \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$\hat{\theta}_2(\mathbf{Y}) = \bar{Y} = \frac{\min\{Y_i\} + \max\{Y_i\}}{2} \text{ et } \hat{\theta}_2(\mathbf{y}) = \bar{y} = \frac{\min\{y_i\} + \max\{y_i\}}{2}$$

Biais d'un estimateur

On appelle biais d'un estimateur $\hat{\theta}$ de θ la quantité

$$\text{bias}[\hat{\theta}(\mathbf{Y})] = \mathbb{E}[\hat{\theta}(\mathbf{Y})] - \theta$$

On dit que

- ▶ $\hat{\theta}(\mathbf{Y})$ est un estimateur sans biais de θ si $\text{bias}[\hat{\theta}(\mathbf{Y})] = 0$
- ▶ $\hat{\theta}(\mathbf{Y})$ est un estimateur asymptotiquement sans biais de θ si

$$\lim_{n \rightarrow \infty} \text{bias}[\hat{\theta}(\mathbf{Y})] = 0$$

Exemple Y_1, \dots, Y_n de moyenne μ ,

- ▶ $\hat{\mu}(\mathbf{Y}) = \frac{1}{n} \sum_{i=1}^n Y_i$ est un estimateur sans biais de μ
- ▶ $\tilde{\mu}(\mathbf{Y}) = \frac{1}{n+3} \sum_{i=1}^n Y_i$ est un estimateur asymptotiquement sans biais de μ

Example Y_1, \dots, Y_n de variance σ^2 ,

► $\hat{\sigma}^2(\mathbf{Y}) = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ estimate sans biais de σ^2

► $\tilde{\sigma}^2(\mathbf{Y}) = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2$ est un estimateur
asymptotiquement sans biais de σ^2

Example Y_1, \dots, Y_n , de loi F . Soit $x \in \mathbb{R}$,

$$\hat{F}(y) = \frac{1}{n} \sum_{i=1}^n \underbrace{\mathbf{1}(Y_i \leq y)}_{X_i}$$

où les variables X_i sont des variables de Bernoulli $\mathcal{B}(p)$ où $p = F(y)$.

$$\mathbb{E}[\hat{F}(y)] = \frac{1}{n} \sum_{i=1}^n \mathbb{P}[Y_i \leq y] = F(y)$$

donc $\hat{F}(y)$ est un estimateur sans biais de $F(y)$, pour tout y .

Moyenne Quadratique (MSE)

Erreur Quadratique Moyenne

On appelle erreur quadratique moyenne d'un estimateur $\hat{\theta}(\mathbf{Y})$ et on note $EQM(\hat{\theta}(\mathbf{Y}))$ la quantité

$$EQM(\hat{\theta}(\mathbf{Y})) = \mathbb{E}[(\hat{\theta}(\mathbf{Y}) - \theta)^2]$$

Un peu de calcul permet d'écrire

$$EQM(\hat{\theta}(\mathbf{Y})) = \text{bias}(\hat{\theta}(\mathbf{Y}))^2 + \text{Var}(\hat{\theta}(\mathbf{Y}))$$

Consistance

Un estimateur $\hat{\theta}(\mathbf{Y})$ est consistant si

$$\lim_{n \rightarrow \infty} EQM(\hat{\theta}(\mathbf{Y})) = 0$$

Moyenne Quadratique (MSE)

Pour un estimateur sans biais

$$EQM(\hat{\theta}(\mathbf{Y})) = \text{Var}(\hat{\theta}(\mathbf{Y}))$$

Un estimateur asymptotiquement sans biais est consistant si

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}(\mathbf{Y})) = 0$$

Efficacité

Soient $\hat{\theta}_1(\mathbf{Y})$ et $\hat{\theta}_2(\mathbf{Y})$ deux estimateurs de θ . $\hat{\theta}_1(\mathbf{Y})$ est plus efficace que $\hat{\theta}_2(\mathbf{Y})$ si $EQM(\hat{\theta}_1(\mathbf{Y})) < EQM(\hat{\theta}_2(\mathbf{Y}))$.

$$eff(\hat{\theta}_1(\mathbf{Y}), \hat{\theta}_2(\mathbf{Y})) = \frac{EQM(\hat{\theta}_2(\mathbf{Y}))}{EQM(\hat{\theta}_1(\mathbf{Y}))} \text{ rapport d'efficacité}$$

Moyenne Quadratique (MSE)

Example: Y_1, \dots, Y_n de moyenne μ ,

$$\hat{\mu}_1(\mathbf{Y}) = \frac{1}{n} \sum_{i=1}^n Y_i \text{ et } \hat{\mu}_2(\mathbf{Y}) = \frac{2}{n} \sum_{i=1}^{n/2} Y_i$$

alors $\text{eff}(\hat{\mu}_1(\mathbf{Y}), \hat{\mu}_2(\mathbf{Y})) = 2$

Moyenne Quadratique (MSE)

Example: Y_1, \dots, Y_n des variables $\mathcal{B}(p)$. Soit $S_n = Y_1 + \dots + Y_n$.
 $S_n \sim \mathcal{B}(n, p)$ donc $\mathbb{E}[S_n] = np$ et $\text{Var}[S_n] = np(1 - p)$.

$$\hat{p}_1 = \frac{S_n}{n} \text{ et } \hat{p}_2 = \frac{S_n + 1}{n + 2}$$

$$\mathbb{E}[\hat{p}_1] = p \text{ et } \text{Var}(\hat{p}_1) = \frac{p(1 - p)}{n}$$

Comme c'est un estimateur sans biais de p , $EQM(\hat{p}_1) = \frac{p(1 - p)}{n}$

$$\mathbb{E}[\hat{p}_2] = \frac{np + 1}{n + 2} \text{ et } \text{Var}(\hat{p}_2) = \frac{\text{Var}(S_n)}{(n + 2)^2} = \frac{np(1 - p)}{(n + 2)^2}$$

$$EQM(\hat{p}_2) = \left[\frac{np + 1}{n + 2} - p \right]^2 + \frac{np(1 - p)}{(n + 2)^2} = \frac{(1 - 2p)^2 + np(1 - p)}{(n + 2)^2}$$

Moyenne Quadratique (MSE)

Aussi, le rapport d'efficacité vaut

$$\text{eff}(\hat{p}_1, \hat{p}_2) = \frac{EQM(\hat{p}_2)}{EQM(\hat{p}_1)} = \frac{n}{(n+2)^2} \left[n + \frac{(1-2p)^2}{p(1-p)} \right]$$

Si $p \sim 1/2$, ce rapport vaut $n^2/(n+2)^2 < 1$.

En fait \hat{p}_2 domine \hat{p}_1 si

$$p \in \left(\frac{1}{2} - \sqrt{\frac{n+1}{2n+1}}, \frac{1}{2} + \sqrt{\frac{n+1}{2n+1}} \right)$$

Exercice

Exercice: X_1, \dots, X_n de loi uniforme sur $[\theta, 2\theta]$ (avec $\theta > 0$).
Montrez que l'estimateur du maximum de vraisemblance de θ est $\max\{x_i\}/2$.