

STT 1000 - STATISTIQUES

ARTHUR CHARPENTIER



Maximum de Vraisemblance

Vraisemblance (Likelihood)

Soit $\mathbf{Y} = (y_1, \dots, y_n)$ un échantillon i.i.d. de variables de loi f_θ . La fonction de vraisemblance est

$$\mathcal{L}(\theta|\mathbf{y}) = \prod_{i=1}^n f_\theta(y_i)$$

L'estimation du maximum de vraisemblance est

$$\hat{\theta}(\mathbf{y}) = \operatorname{argmin}_{\theta \in \Theta} \{ \mathcal{L}(\theta|\mathbf{y}) \} \text{ et } \hat{\theta}(\mathbf{Y}) = \operatorname{argmin}_{\theta \in \Theta} \{ \mathcal{L}(\theta|\mathbf{Y}) \}$$

Maximum de Vraisemblance

Log-Vraisemblance

Soit $\mathbf{Y} = (y_1, \dots, y_n)$ un échantillon i.i.d. de variables de loi f_θ . La fonction de log-vraisemblance est





$$\log \mathcal{L}(\theta|\mathbf{y}) = \sum_{i=1}^n \log f_\theta(y_i)$$

L'estimation du maximum de vraisemblance est

$$\hat{\theta}(\mathbf{y}) = \operatorname{argmin}_{\theta \in \Theta} \{ \log \mathcal{L}(\theta|\mathbf{y}) \} \text{ et } \hat{\theta}(\mathbf{Y}) = \operatorname{argmin}_{\theta \in \Theta} \{ \log \mathcal{L}(\theta|\mathbf{Y}) \}$$

Vraisemblance, cas $\mathcal{B}(p)$


$$\mathbf{y} = \{0, 1, 1, 1\}, Y_i \sim \mathcal{B}(\theta).$$



Vraisemblance, cas $\mathcal{N}(\mu, \sigma^2)$

Pour les paramètres univariés, on peut visualiser la vraisemblance, mais c'est plus compliqué en dimension plus grande...

Vraisemblance $\mathcal{L}(\mu, \sigma^2)$ pour 4 échantillons \mathbf{y}



Vraisemblance, cas $\mathcal{B}(p)$

Exemple 1 : on a fait un sondage sur 15 personnes pour savoir s'ils appréciaient le cours de STT1000, quelle est l'estimation par maximum de vraisemblance de la proportion de gens satisfaits ?

- ce que nous dit la théorie

$$\mathcal{L}(p; \mathbf{x}) = \prod_{i=1}^n f(x_i; p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{s_n} (1-p)^{n-s_n}, \quad s_n = \sum_{i=1}^n x_i$$

$$\log \mathcal{L}(p; \mathbf{x}) = s_n \log(p) + (n - s_n) \log(1 - p)$$

$$\frac{\partial}{\partial p} \log \mathcal{L}(p; \mathbf{x}) = \frac{\partial}{\partial p} s_n \log(p) + (n - s_n) \log(1 - p) = \frac{s_n}{p} - \frac{n - s_n}{1 - p}$$



$$\left. \frac{\partial}{\partial p} \log \mathcal{L}(p; \mathbf{x}) \right|_{p=\hat{p}} = 0 \text{ si et seulement si } \frac{s_n}{\hat{p}} = \frac{n - s_n}{1 - \hat{p}}, \text{ soit } \hat{p} = \frac{s_n}{n} = \bar{x}$$

Vraisemblance, cas $\mathcal{B}(p)$

- ce que nous dit la pratique

Traçons la fonction de (log)vraisemblance $p \mapsto \mathcal{L}(p; \mathbf{x})$

```
1 > n=15
2 > x = c(1, 1, 1, 0, 1, 0, 0, 0, 0, 1, 1, 1, 0, 1, 0)
3 > vraisemblance = fonction(p) prod(dbinom(x,size = 1,
      prob = p))
4 > vect_p = seq(0,1,by=0.01)
5 > plot(vect_p,Vectorize(vraisemblance)(vect_p))
```



Vraisemblance, cas $\mathcal{B}(p)$

- ce que nous dit la pratique

On peut chercher le maximum de la fonction $p \mapsto \mathcal{L}(p; \mathbf{x})$

```
1 > optim(par = .5, fn = function(z) -vraisemblance(z))
2 $par
3 [1] 0.5333252
4
5 $value
6 [1] -3.155276e-05
```

La théorie nous avait dit que ce maximum a une forme particulière,
 $\hat{p} = \bar{x}$

```
1 > mean(x)
2 [1] 0.5333333
```


Vraisemblance, cas $\mathcal{B}(p)$

- ce que nous disent les mathématiques


Comme $\hat{p}(\mathbf{x}) = \bar{x}$, on peut utiliser la loi des grands nombres,

$$Z_n = \sqrt{n} \frac{\hat{p}(\mathbf{X}) - p}{\sqrt{p(1-p)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

mais ici $n = 15$ (approximation Gaussienne peut être mauvaise)

Si $p = 60\%$ la distribution (approchée) de $\hat{p}(\mathbf{X})$ serait


```
1 > u=seq(2/15, 1, by=.001)
2 > plot(u, dnorm(u, .6, sqrt(.4*.6/15)))
```



Vraisemblance, cas $\mathcal{B}(p)$

- ce que nous disent les simulations, si on suppose $\theta = 60\%$

```
1 > theta=rep(NA,1e4)
2 > for(s in 1:1e4){
3 +   x=sample(0:1,size = n,prob = c(.4,.6),replace=
   TRUE)
4 +   neglogL = function(p) -sum(log(dbinom(x,size =
   1,prob = p)))
5 +   theta[s] = optim(par = .5,fn = neglogL)$par
6 + }
7 > hist(theta)
```



Méthode des Moments

Méthode des Moments

Soit $\mathbf{Y} = (y_1, \dots, y_n)$ un échantillon i.i.d. de variables de loi f_θ . Soient $m_k(\theta) = \mathbb{E}[Y^k]$ où $Y \sim f_\theta$, et $\hat{m}_k = \frac{1}{n} \sum_{i=1}^n y_i^k$

le moment empirique. Soit $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_d)$ la solution du système d'équations

$$\begin{cases} m_1(\hat{\theta}) = \hat{m}_1 \\ \vdots \\ m_d(\hat{\theta}) = \hat{m}_d \end{cases}$$

Note: on peut parfois considérer les moments centrés (i.e. $\text{Var}[Y]$ au lieu de $\mathbb{E}[Y^2]$)

Méthode des moments, cas $\mathcal{B}(p)$

Exemple 2 : on a fait un sondage sur 15 personnes pour savoir s'ils appréciaient le cours de STT1000, quelle est l'estimation par la méthode des moments de la proportion de gens satisfaits ?

- ce que nous dit la théorie

$$\mathbb{E}(X) = m_1(p) = p$$

or $\hat{m}_1 = \bar{x}$ donc $\hat{p}(x) = \bar{x}$

- ce que nous disent les mathématiques

Comme $\hat{p}(x) = \bar{x}$, on peut utiliser la loi des grands nombres,

$$Z_n = \sqrt{n} \frac{\hat{p}(\mathbf{X}) - p}{\sqrt{p(1-p)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

mais ici $n = 15$ (approximation Gaussienne peut être mauvaise)

Méthode des moments, cas $\mathcal{B}(n, p)$

Que se passe-t-il si $Y_i \sim \mathcal{B}(n, p)$, où n est aussi inconnu ?

$$\mathbb{E}[Y] = np \text{ et } \text{Var}[Y] = np(1 - p)$$

On va alors résoudre

$$\begin{cases} \hat{n}\hat{p} = \bar{x} = \frac{1}{n} \sum_{i=1}^n y_i \\ \hat{n}\hat{p}(1 - \hat{p}) = s^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \end{cases}$$

soit

$$\hat{p} = \frac{\bar{y} - s^2}{\bar{y}} \text{ et } \hat{n} = \frac{\bar{y}^2}{\bar{y} - s^2}$$

Note: il est possible d'avoir $\hat{p} < 0$

Maximum de Vraisemblance vs Méthode des Moments

Exemple 3 : On observe des données modélisées par une loi de densité $\mapsto \theta y^{\theta-1}$ pour $y \in [0, 1]$. Quels sont les estimateurs de θ ?

```
1 > y = c(0.685, 0.754, 0.853, 0.973, 0.633, 0.97,  
          0.984, 0.888, 0.876, 0.451, 0.637, 0.609, 0.898,  
          0.761, 0.928, 0.819, 0.91, 0.998, 0.758, 0.931,  
          0.981, 0.642, 0.885, 0.553, 0.686)
```

- méthode des moments

$$\mathbb{E}[Y] = \int_0^1 y \cdot \theta y^{\theta-1} dy = \theta \int_0^1 y^{\theta} dy = \theta \left[\frac{y^{\theta+1}}{\theta+1} \right]_0^1 = \frac{\theta}{\theta+1}$$

L'estimateur par la méthode des moments vérifie

$$\bar{y} = \frac{\hat{\theta}}{\hat{\theta} + 1} \text{ soit } \hat{\theta} = \frac{\bar{y}}{1 - \bar{y}}$$

Maximum de Vraisemblance vs Méthode des Moments

- maximum de vraisemblance


$$\log \mathcal{L}(\theta; \mathbf{y}) = n \log(\theta) + (\theta - 1) \sum_{i=1}^n \log(y_i)$$

$$\frac{\partial \log \mathcal{L}(\theta; \mathbf{y})}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^n \log(y_i)$$

$$\left. \frac{\partial \log \mathcal{L}(\theta; \mathbf{y})}{\partial \theta} \right|_{-\theta = \hat{\theta} = 0} \text{ si } \frac{n}{\theta} = - \sum_{i=1}^n \log(y_i), \text{ i.e. } \hat{\theta} = \frac{-n}{\sum_{i=1}^n \log(y_i)}$$

```
1 > (a=mean(y)/(1-mean(y)))  
2 [1] 4.062526  
3 > (b=-25/sum(log(y)))  
4 [1] 4.166513
```

Les deux densités sont très proches




Maximum de Vraisemblance vs Méthode des Moments

Exemple 4 : on a fait un sondage sur 30 personnes pour savoir quelle proportion d'un livre elles ont lu. On suppose que cette proportion suit une loi Beta $\mathcal{B}(a, b)$. Proposez des estimateurs pour a et b (max vraisemblance et méthode des moments).

```
1 > y = c(0.175, 0.324, 0.146, 0.357, 0.148, 0.394,  
         0.458, 0.228, 0.676, 0.371, 0.176, 0.027, 0.565,  
         0.277, 0.282, 0.514, 0.480, 0.421, 0.507, 0.470,  
         0.301, 0.038, 0.427, 0.275, 0.255, 0.075, 0.199,  
         0.378, 0.632, 0.265)
```

Ici $\{Y_1, \dots, Y_n\}$ sont i.i.d. de loi Beta, $\mathcal{B}(a, b)$,

$$f(y) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1}(1-x)^{b-1} \mathbf{1}_{[0,1]}(x)$$



Maximum de Vraisemblance vs Méthode des Moments

Conditions du premier ordre

$$\psi(\hat{a}) - \psi(\hat{a} + \hat{b}) = \frac{1}{n} \sum_{i=1}^n \log(y_i)$$

$$\psi(\hat{b}) - \psi(\hat{a} + \hat{b}) = \frac{1}{n} \sum_{i=1}^n \log(1 - y_i)$$

où $\psi(z) = \frac{\Gamma'(z)}{\Gamma(z)}$ est la fonction digamma.

```
1 > logL = function(ab) -sum(log(dbeta(y, ab[1], ab[2])))
2 > optim(c(1,1), logL)
3 $par
4 [1] 2.026244 4.241886
```

```
1 > library(MASS)
2 > (fity = fitdistr(y, dbeta, list(shape1=1, shape2=1))
   )
3     shape1      shape2
4     2.026245     4.241887
5     (0.4894734) (1.0918760)
```

Maximum de Vraisemblance vs Méthode des Moments

En notant que la moyenne empirique s'écrit

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \text{ et } \mathbb{E}[Y] = \frac{a}{a+b}$$

et que la variance empirique s'écrit

$$v = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \text{ et } \text{Var}[Y] = \frac{ab}{(a+b)^2(a+b+1)}$$

Les estimateurs de la méthode des moments vérifient

$$\begin{cases} [\hat{a} + \hat{b}] \bar{y} = \hat{a} \\ (\hat{a} + \hat{b})^2 [\hat{a} + \hat{b} + 1] v = \hat{a} \hat{b} \end{cases}$$

Maximum de Vraisemblance vs Méthode des Moments

La méthode des moments fournit les estimations suivantes:


$$\hat{a} = \bar{y} \left(\frac{\bar{y}(1 - \bar{y})}{v} - 1 \right),$$

$$\hat{b} = (1 - \bar{y}) \left(\frac{\bar{y}(1 - \bar{y})}{v} - 1 \right).$$

```
1 > bary = mean(y)
2 > vary = var(y)
3 > (a = bary*(bary*(1-bary)/vary - 1))
4 [1] 2.230975
5 > (b = (1-bary)*(bary*(1-bary)/vary - 1))
6 [1] 4.569671
```

Maximum de Vraisemblance vs Méthode des Moments

Les deux estimateurs sont proches
et les densités aussi




Méthode des Moments

Example: $\{y_1, \dots, y_n\}$ de loi $\mathcal{U}([0, \theta])$, $\mathbb{E}[Y] = \theta/2$, alors

$$\bar{y} = \hat{\theta}/2 \text{ i.e. } \hat{\theta} = 2\bar{y}$$

Même si $y_i \leq \theta$ (par hypothèse), on peut avoir $\hat{\theta} < y_j$



Note: estimateur du maximum de vraisemblance pour $\mathcal{U}([0, \theta])$?

Théorème Central Limite

Soit (Y_n) une suite de variables aléatoires réelles indépendantes et de même loi admettant une espérance μ et une variance σ^2 . La moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{k=1}^n Y_k$ centrée converge vers une loi normale :

$$\sqrt{n}[\bar{X}_n - \mu] \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$$

Delta-Method

Comme $\sqrt{n}[\bar{X}_n - \mu] \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$, alors

$$\sqrt{n}[g(\bar{X}_n) - g(\mu)] \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2 \cdot [g'(\mu)]^2)$$

pour toute fonction g telle que $g'(\mu)$ existe et est non-nulle.

Méthode des Moments

Example: $\{Y_1, \dots, Y_n\}$ de loi $\mathcal{U}([- \theta, \theta])$,

$\mathbb{E}[Y] = 0$ et $\text{Var}[Y] = \theta^2/3$,

On ne peut pas utiliser le premier modèle, on utilise le second,

$$s^2 = \hat{\theta}^2/3 \text{ et } \hat{\theta} = \sqrt{3s^2}$$

Comme $\mathbb{E}[Y] = 0$, $\mathbb{E}[Y^2] = \text{Var}[Y]$

Méthode des Moments: quel(s) moment(s) ?

Considérons un exemple (simple)

Example: $\{Y_1, \dots, Y_n\}$ de loi lornormale $LN(\theta, 1)$,

$$\begin{cases} \mathbb{E}[Y] = e^{\mu+\sigma^2/2} \\ \text{Var}Y = (e^{\sigma^2}-1)e^{2\mu+\sigma^2} \\ \text{skew}(Y) = (e^{\sigma^2}+2)\sqrt{e^{\sigma^2}-1}, \text{ etc} \end{cases}$$

etc. Comme $Y = \exp[X]$ où $X \sim \mathcal{N}(\theta, 1)$,



$$\mathbb{E}[Y^k] = \mathbb{E}[\exp(kX)] = M(K) = \exp\left(k\theta + \frac{k^2}{2}\right) = \psi(\theta)$$

où M est la fonction génératrice des moments (de la loi normale)

$$\hat{\theta}_k = \psi^{-1}\left(\frac{1}{n} \sum_{i=1}^n y_i^k\right) = \frac{1}{k} \left[\log\left(\frac{1}{n} \sum_{i=1}^n y_i^k\right) - \frac{k^2}{2} \right]$$

Méthode des Moments: quel(s) moment(s) ?

Échantillons de taille $n = 50$ tirés suivant des lois $LN(0, 1)$
on voit que l'on $\hat{\theta}_k$ est un estimateur (possiblement) biaisé,
et dont la variance augmente avec k



Si possible on utilise les premiers moments (moyenne, variance si
deux moments sont nécessaire)