



STT 1000 - STATISTIQUES

ARTHUR CHARPENTIER



Inférence Ponctuelle & Intervalle de Confiance

Estimation ponctuelle : $\hat{\theta}(\mathbf{y}) \in \mathbb{R}$ (ou \mathbb{R}^d)

Intervalle de confiance: $IC_{\alpha} = [\hat{a}(\mathbf{Y}), \hat{b}(\mathbf{Y})] \subset \mathbb{R}$

Ici, on va se poser la question sur la valeur prise par θ .

Example: *“si la fréquentation moyenne par mois pendant la saison d'ouverture dépasse 3500, nous engagerons des moyens financiers pour ouvrir la piste cyclable à l'année”*

y_i : fréquentation moyenne par mois

▶ si $\mathbb{E}[Y] > 3500$ ouverture

▶ si $\mathbb{E}[Y] \leq 3500$ fermeture

Hypothèse 1: Y_i suit une loi normale $\mathcal{N}(\mu, \sigma^2)$, et les Y_i sont des variables indépendantes

Hypothèse 2: Y_i suit une loi de Poisson $\mathcal{P}(\lambda)$, et les Y_i sont des variables indépendantes

data : $\mathbf{y} = \{3400, 4204, 4224, 4255, 4111, 3005\}$

Inférence Ponctuelle & Intervalle de Confiance

Hypothèse 1-2: $\hat{\mu}(\mathbf{y}) = \bar{y}$ et $\hat{\lambda}(\mathbf{y}) = \bar{y}$

Pour trancher entre les deux hypothèses :

- ▶ si $\bar{y} > y^*$, $\mathbb{E}[Y] > 3500$ est l'hypothèse la plus crédible
- ▶ si $\bar{y} \leq y^*$, $\mathbb{E}[Y] \leq 3500$ est l'hypothèse la plus crédible

Comment choisir y^* ?

Test, rejet & valeur critique


La région $\{\bar{y} \leq y^*\}$ est la région de rejet,
 y^* est appelée valeur critique.

Tentons quelques scénarios, par simulations (pour comprendre)

Valeur critique et Simulation

Example: $\bar{y} \sim 3866.5$, scenario $\mu = 3500$ ($\sigma = 530$), $y^* = 3600$


$\mathbb{P}[Z > y^*] \sim 42.51\%$ avec $\bar{Z} \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$



Valeur critique et Simulation

Example: $\bar{y} \sim 3866.5$, scenario $\mu = 3600$ ($\sigma = 530$), $y^* = 3500$


$\mathbb{P}[Z > y^*] \sim 57.48\%$ avec $\bar{Z} \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$



Valeur critique et Simulation

Example: $\bar{y} \sim 3866.5$, scenario $\mu = 3200$ ($\sigma = 530$), $y^* = 3500$


$\mathbb{P}[Z > y^*] \sim 28.57\%$ avec $\bar{Z} \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$



Valeur critique et Simulation

Example: $\bar{y} \sim 3866.5$, scenario $\mu = 3800$ ($\sigma = 530$), $y^* = 3500$

$\mathbb{P}[Z > y^*] \sim 71.43\%$ avec $\bar{Z} \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$



Valeur critique et Simulation

Pour une règle de décision fixée (y^*), correspondant à une région de rejet $\{y > y^*\}$, deux erreurs de décision sont possible, en fonction de la valeur de μ supposée.

- ▶ $\mu \notin \{y > y^*\}$ et $\bar{y} \in \{y > y^*\}$
- ▶ $\mu \in \{y > y^*\}$ et $\bar{y} \notin \{y > y^*\}$

On ne peut pas contrôler les deux erreurs en même temps...

On se donne $\alpha \in (0, 1)$, et on cherche y^* tel que

$$\mathbb{P}[\bar{Y} > y^* | H_0 \text{ est vraie}] = \alpha$$

Valeur critique et Simulation

Comparer $\hat{\mu}(\mathbf{y})$ à y^\star peut se réécrire

$$\frac{\hat{\mu}(\mathbf{y}) - y_0}{\sigma\sqrt{n}} \leftrightarrow u_\alpha$$

Inférence Ponctuelle & Intervalle de Confiance

- ▶ H_0 : hypothèse nulle, $\theta \in \Theta_0$
- ▶ H_1 : hypothèse alternative, $\theta \in \Theta_1$ (souvent $\theta \notin \Theta_0$)

Probabilité critique (p -value)

La probabilité critique (p -value) associée à une statistique de test est la probabilité d'observer des valeurs aussi ou plus extrêmes que la valeur observée dans l'échantillon sachant que H_0 est vraie.

Elle est le plus petit seuil auquel on peut rejeter H_0 . Pour faire simple, c'est le (plus petit) risque à encourir pour rejeter H_0 et accepter H_1 .

En fonction de celle-ci, la règle de décision peut se réécrire de la façon suivante : on rejete H_0 (ou on accepte H_1) si $p\text{-valeur} < \alpha$.

Inférence Ponctuelle & Intervalle de Confiance

Il est inévitable que des erreurs soient possibles dans la prise de décision suite à un test.

On contrôle ici

$$\mathbb{P}(\text{rejeter } H_0 | H_0 \text{ est vraie}) = \mathbb{P}(\text{accepter } H_1 | H_0 \text{ est vraie})$$

en définissant la région de rejet de telle sorte que cette probabilité α soit petite.

Mais un autre type d'erreur est possible :

$$\mathbb{P}(\text{ne pas rejeter } H_0 | H_0 \text{ est fausse}) = \mathbb{P}(\text{ne pas accepter } H_1 | H_0 \text{ est fausse})$$